第14章 TinyC 前端

上一章介绍了 bison 中一些常用功能的使用方法,bison 是一个非常强大的语法分析工具,读者还可以阅读一下 bison 的文档进行更深入的学习。本章介绍如何利用 flex 和 bison 实现 TinyC 编译器的前端,建议读者先复习一下 第 5 章 手工编译 TinyC ,再来看本章的代码。

14.1 第 0.1 版

首先对上一章的雏形版本稍微升级一下,增加变量声明和 print 语句,一共有 5 个文件:

词法分析文件: scanner.l

```
%{
#define YYSTYPE char *
#include "y.tab.h"
int cur line = 1;
void yyerror(const char *msg);
void unrecognized char(char c);
#define _DUPTEXT {\(\frac{1}{2}\)yylval = strdup(yytext);}
%}
/* note \042 is '"' */
OPERATOR 
                 ([-/+*()=,;])
INTEGER
                 ([0-9]+)
STRING
                 (\042[^\042\n]*\042)
                 ([_a-zA-Z][_a-zA-Z0-9]*)
IDENTIFIER
WHITESPACE
                 ([\t]*)
%%
                 { return yytext[0]; }
{OPERATOR}
                 { return T Int; }
"int"
"print"
                 { return T Print; }
                 { DUPTEXT; return T IntConstant; }
{INTEGER}
                  DUPTEXT; return T StringConstant; }
{STRING}
                 { DUPTEXT; return T Identifier; }
{IDENTIFIER}
{WHITESPACE}
                 { /* ignore every whitespace */ }
n
                 { cur line++; }
                 { unrecognized char(yytext[0]); }
%%
```

```
int yywrap(void) {
    return 1;
}

void unrecognized_char(char c) {
    char buf[32] = "Unrecognized character: ?";
    buf[24] = c;
    yyerror(buf);
}

void yyerror(const char *msg) {
    printf("Error at line %d:\n\t%s\n", cur_line, msg);
    exit(-1);
}
```

语法分析文件: parser.y

```
%{
#include <stdio.h>
#include <stdlib.h>
void yyerror(const char*);
#define YYSTYPE char *
%}
%token T StringConstant T IntConstant T Identifier T Int T Print
%left '+' '-'
%left '*' '/'
%right U neg
%%
S:
    Stmt
                                   { /* empty */ }
    S Stmt
                                   { /* empty */ }
Stmt:
    VarDecl ';'
                                   { printf("\n\n"); }
                                   { /* empty */ }
    Assign
    Print
                                   { /* empty */ }
VarDecl:
    T Int T Identifier
                                   { printf("var %s", $2); }
    T_Int T_Identifier { printf("var %s", $2);
VarDecl ',' T_Identifier { printf(", %s", $3); }
Assign:
    T Identifier '=' E ';' { printf("pop %s\n\n", $1); }
```

```
Print:
   T Print '(' T StringConstant Actuals ')' ';'
                                 { printf("print %s\n\n", $3); }
;
Actuals:
   /* empty */
                                 { /* empty */ }
   Actuals', E
                                 { /* empty */ }
Ε:
    E '+' E
                                 { printf("add\n"); }
    E '-' E
                                 { printf("sub\n"); }
    E '*' E
                                 { printf("mul\n"); }
    E '/' E
                                 { printf("div\n"); }
    '-' E %prec U neg
                                 { printf("neg\n"); }
                                 { printf("push %s\n", $1); }
    T IntConstant
    T Identifier
                                 { printf("push %s\n", $1); }
    '(' E ')'
                                 { /* empty */ }
%%
int main() {
    return yyparse();
}
```

makefile 文件: makefile

```
OUT
         = tcc
TESTFILE = test.c
SCANNER = scanner.l
PARSER
         = parser.y
CC
         = qcc
         = lex.yy.o y.tab.o
0BJ
TESTOUT = $(basename $(TESTFILE)).asm
OUTFILES = lex.yy.c y.tab.c y.tab.h y.output $(OUT)
.PHONY: build test simulate clean
build: $(OUT)
test: $(TESTOUT)
simulate: $(TESTOUT)
        python pysim.py $<</pre>
clean:
        rm -f *.o $(OUTFILES)
```

测试文件: test.c

```
int a, b, c, d;
a = 1 + 2 * ( 2 + 2 );
c = 5;
d = 10;
b = c + d;
print("a = %d, b = %d, c = %d, d = %d", a, b, c, d);
```

Pcode 模拟器: pysim.py , 已经在第 4 章中介绍了。

这个版本在上一章的雏形版本的基础上,进行了以下扩充:

词法分析文件中:

增加了 T_StringConstant, T_Int, T_Print 类型的 token ,以及相应的正则表达式;

增加了一个 _DUPTEXT 宏,表示 yylval = strdup(yytext)。

语法分析文件中:

增加了 VarDecl 和 Print 两个非终结符以及相应的产生式。

本版本的语法分析文件中,同样要注意源文件的解析过程中各产生式的折叠顺序以及相应的 Pcode 生成顺序。

makefile 里面是编译和测试这个程序的命令,在终端输入 make 后,将编译 生成可执行文件 tcc ,然后输入 make test , (相当于 "./tcc < test.c > test.asm"),将输出 test.asm 文件,内容如下:

```
var a, b, c, d
push 1
push 2
push 2
push 2
add
mul
add
pop a
push 5
pop c
push 10
pop d
push c
push d
add
pop b
push a
push b
push c
push d
print "a = %d, b = %d, c = %d, d = %d"
```

可以看出 test.c 文件里的所有语句都被转换成相应的 Pcode 了。再用 Pcode 模拟器运行一下这些 Pcode ,在终端输入 "make simulate" (相当于 "python pysim.py test.asm"),将输出:

```
a = 9, b = 5, c = 10, d = 15
```

14.2 第 0.5 版

在第 0.1 版的基础上升级,增加函数定义及调用语句、注释等功能,一共有 5 个文件:

词法分析文件: scanner.l

```
%{
#define YYSTYPE char *
#include "y.tab.h"
int cur_line = 1;
void yyerror(const char *msg);
void unrecognized_char(char c);
```

```
void unterminate string();
#define DUPTEXT {yylval = strdup(yytext);}
%}
/* note \042 is '"' */
WHITESPACE
                      ([ \t \r\a]+)
SINGLE COMMENT1
                      ("//"[^{n}]*)
                      ("#"[^\n]*)
SINGLE COMMENT2
OPERATOR
                      ([+*-/%=,;!<>(){}])
INTEGER
                      ([0-9]+)
IDENTIFIER
                      ([a-zA-Z][a-zA-Z0-9]*)
UNTERM_STRING
                      (\042[^\042\n]*)
STRING
                      (\042[^\042\n]*\042)
%%
                      { cur_line++; }
\n
{WHITESPACE}
{WHITESPACE} { /* ignore every whitespace */ }
{SINGLE_COMMENT1} { /* skip for single line comment */
{SINGLE_COMMENT2} { /* skip for single line comment */
                      { /* ignore every whitespace */ }
{OPERATOR}
                      { return yytext[0]; }
"int"
                      { return T Int; }
                      { return T Void; }
"void"
"return"
                      { return T Return; }
"print"
                      { return T Print; }
{INTEGER}
                      { DUPTEXT return T IntConstant; }
                      { DUPTEXT return T StringConstant; }
{STRING}
                      { DUPTEXT return T Identifier; }
{IDENTIFIER}
{UNTERM STRING}
                      { unterminate string(); }
                      { unrecognized char(yytext[0]); }
%%
int yywrap(void) {
    return 1;
}
void unrecognized char(char c) {
    char buf[32] = "Unrecognized character: ?";
    buf[24] = c;
    yyerror(buf);
}
void unterminate string() {
    yyerror("Unterminate string constant");
}
void yyerror(const char *msg) {
    fprintf(stderr, "Error at line %d:\n\t%s\n", cur line, msg);
```

}

```
exit(-1);
```

语法分析文件: parser.y

```
%{
#include <stdio.h>
#include <stdlib.h>
void yyerror(const char*);
#define YYSTYPE char *
%}
%token T_Int T_Void T_Return T_Print T_IntConstant
%token T StringConstant T Identifier
%left '+' '-'
%left '*' '/'
%right U_neg
%%
Program:
   /* empty */ { /* empty */ }
Program FuncDecl { /* empty */ }
FuncDecl:
    RetType FuncName '(' Args ')' '{' VarDecls Stmts '}'
                             { printf("ENDFUNC\n\n"); }
;
RetType:
                             { /* empty */ }
    T Int
                             { /* empty */ }
    T Void
FuncName:
    T Identifier
                             { printf("FUNC @%s:\n", $1); }
Args:
    /* empty */
                             { /* empty */ }
                             { printf("\n\n"); }
    _Args
_Args:
    T Int T Identifier { printf("arg %s", $2); }
   Args ',' T Int T Identifier
                             { printf(", %s", $4); }
```

```
VarDecls:
   /* empty */ { /* empty */ }
VarDecls VarDecl ';' { printf("\n\n"); }
VarDecl:
   T Int T Identifier { printf("var %s", $2); }
   VarDecl',' T Identifier
                             { printf(", %s", $3); }
Stmts:
                           \{ /* empty */ \}
  /* empty */
                           { /* empty */ }
   Stmts Stmt
Stmt:
                           { /* empty */ }
   AssignStmt
   PrintStmt
                           { /* empty */ }
                            { /* empty */ }
   CallStmt
                            { /* empty */ }
   ReturnStmt
AssignStmt:
   T Identifier '=' Expr ';'
                             { printf("pop %s\n\n", $1); }
PrintStmt:
   T_Print '(' T_StringConstant PActuals ')' ';'
                             { printf("print %s\n\n", $3); }
;
PActuals:
  /* empty */
   /* empty */
PActuals ',' Expr { /* empty */ }
{ /* empty */ }
CallStmt:
  CallExpr ';' { printf("pop\n\n"); }
CallExpr:
   T Identifier '(' Actuals ')'
                             { printf("$%s\n", $1); }
Actuals:
   /* empty */ { /* empty */ }
Expr PActuals { /* empty */ }
```

```
ReturnStmt:
   T_Return Expr ';' { printf("ret ~\n\n"); }
    T Return ';'
                            { printf("ret\n\n"); }
Expr:
                            { printf("add\n"); }
    Expr '+' Expr
    Expr '-' Expr
                            { printf("sub\n"); }
   Expr '*' Expr
                            { printf("mul\n"); }
                            { printf("div\n"); }
    Expr '/' Expr
    '-' Expr %prec U neg
                            { printf("neg\n"); }
                            { printf("push %s\n", $1); }
   T IntConstant
                            { printf("push %s\n", $1); }
   T Identifier
                            { /* empty */ }
   CallExpr
    '(' Expr ')'
                            { /* empty */ }
%%
int main() {
    return yyparse();
}
```

makefile 文件: makefile, 和第 0.1 版本中唯一不同的只有 "python pysim.py \$< -a" 那一行有一个 "-a"。

测试文件: test.c

```
// tiny c test file
int main() {
    int a, b, c, d;

    c = 2;
    d = c * 2;

    a = sum(c, d);
    b = sum(a, d);
    print("c = %d, d = %d", c, d);
    print("a = sum(c, d) = %d, b = sum(a, d) = %d", a, b);

    return 0;
}
int sum(int a, int b) {
    int c, d;
    return a + b;
}
```

Pcode 模拟器: pysim.py , 已经在第 4 章中介绍了。

这个版本在第 0.1 版本的基础上,进行了以下扩充:

词法分析文件中:

增加了 T_Void 和 T_Return 类型的 token ,以及相应的正则表达式;

增加了单行注释的过滤功能;增加了一个错误处理函数: unterminate_string ,该函数可以检查出未结束的字符串 (不匹配的双引号)的词法错误。

语法分析文件中:

增加了 Program, FuncDecl, Args, Actuals, CallExpr 等非终结符以及相应的产生式,请注意各产生式的折叠顺序以及相应的 Pcode 生成顺序。

makefile 里面是编译和测试这个程序的命令,内容和第 0.1 版的基本一样,但增加了一些变量以便于扩充,另外,"python pysim.py..." 那一行最后的命令行参数是 "-a"。在终端输入 make 后,将编译生成可执行文件 tcc ,然后输入 make test ,(相当于 "./tcc < test.c > test.asm") ,将输出 test.asm 文件,内容如下:

```
FUNC @main:
var a, b, c, d
push 2
pop c
push c
push 2
mul
pop d
push c
push d
$sum
pop a
push a
push d
$sum
pop b
push c
```

push d

```
print "c = %d, d = %d"
push a
push b
print "a = sum(c, d) = %d, b = sum(a, d) = %d"
push 0
ret ~
ENDFUNC
FUNC @sum:
arg a, b
var c, d
push a
push b
add
ret ~
ENDFUNC
```

可以看出 test.c 文件里的所有语句都被转换成相应的 Pcode 了。再用 Pcode 模拟器运行一下这些 Pcode ,在终端输入 "make simulate" (相当于 "python pysim.py test.asm -a",注意最后有一个"-a") ,将输出:

```
c = 2, d = 4
a = sum(c, d) = 6, b = sum(a, d) = 10
```

有兴趣的读者还可以使用 "python pysim.py test.asm -da" 来逐句运行一下这 个 Pcode 文件。

14.3 第 1.0 版

继续在第 0.5 版的基础上升级,增加 if 和 while 语句、比较运算符和逻辑运算 符以及 readint 命令,就形成了完整的 TinyC 前端。一共有 7 个文件:

词法分析文件: scanner.l

```
%{
#define YYSTYPE char *
#include "y.tab.h"
int cur line = 1;
void yyerror(const char *msg);
void unrecognized char(char c);
void unterminate string();
```

void unrecognized char(char c) {

}

```
char buf[32] = "Unrecognized character: ?";
buf[24] = c;
yyerror(buf);
}

void unterminate_string() {
   yyerror("Unterminate string constant");
}

void yyerror(const char *msg) {
   fprintf(stderr, "Error at line %d:\n\t%s\n", cur_line, msg);
   exit(-1);
}
```

语法分析文件: parser.y

```
%{
#include <stdio.h>
#include <stdlib.h>
void yyerror(const char*);
#define YYSTYPE char *
int ii = 0, itop = -1, istack[100];
int ww = 0, wtop = -1, wstack[100];
#define _BEG_IF
                    {istack[++itop] = ++ii;}
#define _END_IF
                    {itop--;}
#define i
                    (istack[itop])
#define BEG WHILE {wstack[++wtop] = ++ww;}
#define _END WHILE {wtop--;}
#define w
                    (wstack[wtop])
%}
%token T Int T Void T Return T Print T ReadInt T While
%token T If T Else T Break T Continue T Le T Ge T Eq T Ne
%token T And T Or T IntConstant T StringConstant T Identifier
%left '='
%left T Or
%left T And
%left T Eq T Ne
%left '<' '>' T Le T Ge
%left '+' '-'
%left '*' '/' '%'
%left '!'
%%
```

Program:

```
第14章 TinyC 前端 — 自己动手写编译器
2018/12/7
       BreakStmt
                                  { /* empty */ }
       ContinueStmt
                                 { /* empty */ }
   AssignStmt:
       T_Identifier '=' Expr ';'
                                  { printf("\tpop %s\n\n", $1); }
   ;
   PrintStmt:
       T Print '(' T StringConstant PActuals ')' ';'
                                  { printf("\tprint %s\n\n", $3); }
   PActuals:
      /* empty */ { /* empty */ }
PActuals ',' Expr { /* empty */ }
   CallStmt:
       CallExpr ';'
                               { printf("\tpop\n\n"); }
   CallExpr:
       T_Identifier '(' Actuals ')'
                                  { printf("\t$%s\n", $1); }
   Actuals:
      /* empty */ { /* empty */ }
Expr PActuals { /* empty */ }
   ReturnStmt:
       T_Return Expr ';' { printf("\tret ~\n\n"); }
T_Return ';' { printf("\tret\n\n"); }
   IfStmt:
       If TestExpr Then StmtsBlock EndThen EndIf
                                  { /* empty */ }
       If TestExpr Then StmtsBlock EndThen Else StmtsBlock EndIf
                                  { /* empty */ }
   TestExpr:
     '(' Expr ')'
                                { /* empty */ }
   StmtsBlock:
       '{' Stmts '}'
                                { /* empty */ }
```

```
If:
                   { _BEG_IF; printf("_begIf_%d:\n", _i); }
   T If
Then:
   /* empty */ { printf("\tjz _elIf_%d\n", _i); }
EndThen:
   /* empty */ { printf("\tjmp _endIf_%d\n_elIf_%d:\n", _i, _
Else:
   T Else
                  { /* empty */ }
EndIf:
   /* empty */ { printf("_endIf_%d:\n\n", _i); _END_IF; }
WhileStmt:
   While TestExpr Do StmtsBlock EndWhile
                   { /* empty */ }
;
While:
               { _BEG_WHILE; printf("_begWhile_%d:\n", _w); }
   T While
Do:
   /* empty */ { printf("\tjz _endWhile_%d\n", _w); }
EndWhile:
   /* empty */ { printf("\tjmp begWhile %d\n endWhile %d:\n\
                               _w, _w); _END_WHILE; }
;
BreakStmt:
   T_Break ';' { printf("\tjmp _endWhile_%d\n", _w); }
ContinueStmt:
   T Continue ';' { printf("\tjmp begWhile %d\n", w); }
Expr:
   Expr '+' Expr
                           { printf("\tadd\n"); }
                           { printf("\tsub\n"); }
   Expr '-' Expr
                           { printf("\tmul\n"); }
   Expr '*' Expr
                           { printf("\tdiv\n"); }
   Expr '/' Expr
```

makefile 文件: makefile , 内容和 第 0.5 版是一样的。

测试文件: test.c, 就是第二章的的示例源程序。

```
#include "for_gcc_build.hh" // only for gcc, TinyC will ignore it.
int main() {
    int i;
    i = 0;
    while (i < 10) {
        i = i + 1;
        if (i == 3 || i == 5) {
            continue;
        }
        if (i == 8) {
            break;
        }
        print("%d! = %d", i, factor(i));
    }
    return 0;
}</pre>
```

```
int factor(int n) {
    if (n < 2) {
        return 1;
    }
    return n * factor(n - 1);
}</pre>
```

测试文件包: samples.zip ,包含了 7 个测试文件。

测试脚本: test_samples.sh。

Pcode 模拟器: pysim.py。

这个版本在第 0.1 版本的基础上,进行了以下扩充:

词法分析文件中:

增加了 T_Void 和 T_Return 类型的 token ,以及相应的正则表达式。

语法分析文件中:

增加了 IfStmt, WhileStmt, BreakStmt, ContinueStmt, ReadInt 等非终结符以及相应的产生式,请注意各产生式的折叠顺序以及相应的 Pcode 生成顺序;

增加了比较运算符、逻辑运算符,以及相应的优先级;

在 Declarations 段,增加了几个全局变量和宏:

这些全局变量和宏配合后面的 if/while 语句产生式中的 action 使用,是该文件中的最精妙的部分,它们的作用

是:在生成 if 和 while 语句块的 Pcode 的过程中,给相应的 Label 进行编号。它们给每个 if 语句块和每个 while 语句块一个唯一的编号,使不同的 if/while 语句块的 jmp 不相互冲突。其中 _i 永远是当前的 if 语句块的编号, _w 永远是当前的 while 语句块的编号; ii/ww 永远是目前解析到的 if/while 语句块的总数。

将以上所有文件都放在当前目录,在终端直接输入 make test ,将自动编译生成 TinyC 前端: **tcc** ,并自动调用 tcc 将 test.c 编译成 test.asm 文件,内容如下,和第 5 章的手工编译的结果差不多吧:

```
FUNC @main:
        var i
        push 0
        pop i
begWhile 1:
        push i
        push 10
        cmplt
        jz endWhile 1
        push i
        push 1
        add
        pop i
begIf 1:
        push i
        push 3
        cmpeq
        push i
        push 5
        cmpeq
        or
        jz elIf 1
        jmp _begWhile_1
        jmp _endIf_1
elIf 1:
endIf 1:
begIf 2:
        push i
        push 8
        cmpeq
        jz _elIf_2
        \verb"jmp _endWhile_1"
        jmp _endIf_2
elIf 2:
```

```
_endIf_2:
        push i
        push i
        $factor
        print "%d! = %d"
        jmp _begWhile_1
_endWhile_1:
        push 0
        ret ~
ENDFUNC
FUNC @factor:
        arg n
_begIf_3:
        push n
        push 2
        cmplt
        jz _elIf_3
        push 1
        ret ~
        jmp _endIf_3
_elIf_3:
endIf 3:
        push n
        push n
        push 1
        sub
        $factor
        mul
        ret ~
ENDFUNC
```

再输入 "make simulate",将输出:

```
1! = 1
2! = 2
4! = 24
6! = 720
7! = 5040
```

和第二章中用 gcc 编译并运行此文件的结果完全一样。

再把测试文件包里的所有源文件全部测试一遍,将 samples.zip 解压到 samples 目录下,测试脚本 test_samples.sh 将分别调用 tcc 和 gcc 编译测试文件包中的每一个文件,并分别使用 pysim.py 和 操作系统 运行编译得到的目标文件,内容如下:

在终端输入 bash ./test_samples.sh ,将分别输出一系列的结果,典型输出如下,可以看到 gcc 和 tcc 编译运行的结果完全一致。

```
build with tcc, the output are:
The first 10 number of the fibonacci sequence:
fib(1)=1
fib(2)=1
fib(3)=2
fib(4)=3
fib(5)=5
fib(6)=8
fib(7)=13
fib(8)=21
fib(9)=34
fib(10)=55
build with gcc, the output are:
The first 10 number of the fibonacci sequence:
fib(1)=1
fib(2)=1
fib(3)=2
fib(4)=3
fib(5)=5
fib(6)=8
fib(7)=13
fib(8)=21
fib(9)=34
fib(10)=55
```

至此 TinyC 前端完成。

第 14 章完